

Universität Hamburg
Fachbereich: Sozialwissenschaften
Fachgebiet: Politikwissenschaft
Seminar: Musterseminar
Dozenten: Prof. Dr. Kai-Uwe Schnapp
PD Dr. Falk Daviter
Wintersemester 2018/19



Forschungsarbeit

Geschlechterunterschiede im Deutschen Bundestag

Arbeitstitel

tba

Josef Holnburger
Matrikelnummer: XXX
XXX
XXX
E-Mail: josef@holnburger.com

Inhaltsverzeichnis

Abbildungsverzeichnis	I
Tabellenverzeichnis	I
1. Einleitung	1
2. Generelles zur Datenerhebung	2
2.1. XML-Knoten und Attribute	3
3. Erhebung der Daten des 19. Bundestags	10
3.1. Überblick der Reden	12
3.2. Inhalte der Reden	14
3.3. Daten der Abgeordneten	14
4. Auswertung	19
4.1. Länge der Reden	21
4.2. Inhalte der Reden	25
5. Topic Modeling	31
Literatur- und Quellverzeichnis	32

Abbildungsverzeichnis

3.1. Auswertung der Geschlechteranteile aller Deutscher Bundestage	18
--	----

Tabellenverzeichnis

3.1. Reden Nach Fraktion im Deutschen Bundestag	13
3.2. Bundestagsabgeordnete aller Wahlperioden nach Geschlecht	16

1. Einleitung

Zusammen mit Gina-Gabriela Görner analysiere ich die Protokolle des Deutschen Bundestages auf mögliche Geschlechterunterschiede. Hierfür wollen wir die Anzahl aber auch Inhalte der Reden mehrerer Wahlperioden des Bundestags untersuchen. Dieses Projekt wurde auch für das European Symposium Series on Societal Challenges eingereicht und wir dürfen es dort mit einem Plakat vorstellen.

Wir orientieren uns vor allem an der Forschung von Bäck et al. (2014), welche das schwedische Parlament auf mögliche Geschlechterunterschiede und Diskriminierung hin untersucht haben. In dieser Studie wurden Unterschiede sowohl in der Anzahl als auch bezüglich des Inhalts der Reden festgestellt. Auch im schwedischen Parlament sind Männer deutlich häufiger zu hören – obwohl es mit einem Frauenanteil von 40 Prozent die höchste Quote europäischer Parlamente aufweist (Bäck et al. 2014: 505). Männer sprechen in ihren Reden häufiger über *hard topics*, bei *soft topics* ist der Redeanteil hingegen ausgeglichen (ebd: 513ff.). Die Konstruktion der *hard* und *soft topics* geht dabei auf Wangnerud (2000) zurück und ist nicht unkritisch – hier werden durchaus Geschlechterstereotype aufrechterhalten oder gar reproduziert, indem “typische” Frauen- und Männerthemen identifiziert werden. Wangnerud hat in ihrer Untersuchung die Mitglieder des schwedischen *Riksdag* bezüglich ihrer Aktivitäten befragt. Das Ergebnis von Bäck et al. (2014) ist deshalb auch nicht besonders überraschend – bestätigt es doch nur, dass die Fachpolitiker_innen häufiger über ihre Themen auch im Plenum reden.

In dieser Arbeit soll anders vorgegangen werden. Die Inhalte der Reden im Bundestag sollen ohne vorherige Identifikation vermeintlicher Frauen- und Männerthemen untersucht werden. Hierbei nutzen wir die Möglichkeiten des *Topic Modelling* um zunächst generell Themen der Reden im Bundestag zu identifizieren und diese anschließend auf mögliche Geschlechterunterschiede untersuchen. Natürlich wollen auch wir die unterschiedlichen Redeanteile untersuchen.

Da ich den Prinzipien der Open Science sehr viel abgewinnen kann, soll die Erhebung und Auswertung möglichst transparent und nachvollziehbar dargestellt werden.

Die Datei soll anschließend in einen *Dataframe* umgewandelt werden. Dies erleichtert die weitere Arbeit und im weiteren Verlauf können die Daten einfacher nach Geschlecht, Partei, Datum oder Wahlperiode gefiltert werden. Hierbei wird vor allem mit den Funktionen `xml_node()` und `xml_attr()` gearbeitet. Zum Verständnis bietet sich hier ein kleiner Diskurs an.

2.1. XML-Knoten und Attribute

Nachdem die Datei eingelesen wurde, lohnt sich ein Blick auf die Rohdaten:

```
<rede id="ID196105400">
  <p klasse="redner"><redner id="11004826"><name><vorname>Siemtje</vorname><nachname>
  <p klasse="J_1">Lieber Jürgen Trittin, Sie haben gerade eigentlich das wiederholt,
  <kommentar>(Beifall bei der SPD)</kommentar>
</rede>
```

In diesem Beispiel wird das XML-Fragment in die Variable `xml_example` geladen und ausgewertet. Die Knoten eines XML-Documents werden durch `<>` und `</>` eingefasst. Beispielsweise können die Knoten mit den Namen “Kommentar” folgendermaßen extrahiert werden:

```
xml_example %>% xml_nodes("kommentar")
```

```
## {xml_nodeset (1)}
## [1] <kommentar>(Beifall bei der SPD)</kommentar>
```

Bei der Ausgabe fällt jedoch auf, dass die Datei weiterhin eine XML-Datei bleibt und die Knoteninformationen ebenfalls extrahiert werden. Mittels der Funktion `xml_text()` kann das Ergebniss in einen in einen Character-String umwandelt werden.

```
xml_example %>% xml_nodes("kommentar") %>% xml_text()
```

```
## [1] "(Beifall bei der SPD)"
```

Die Ergebnisse werden in einer Liste zusammengefasst und können beispielsweise in einem

Datenframe umgewandelt werden.

Die Attribute eines Knotens finden sich in den Klammern nach dem Gleichheitszeichen: `<knotenname attribut=inhalt">....` Die Werte eines Attributes (und auch den Attributnamen) können mit der Funktion `xml_attr()` extrahiert werden.

```
xml_example %>% xml_node("rede") %>% xml_attr("id")
```

```
## [1] "ID196105400"
```

Mit dieser kurzen Exkursion können wir nun eine Funktion bauen, welche auf die für uns relevanten Daten aus dem XML-Dokument extrahiert und anschließend in einen Datenframe umwandelt.

```
get_overview_df <- function(x){
  rede_id <- x %>% xml_attr("id")
  redner_id <- x %>% xml_node("redner") %>% xml_attr("id")
  redner_vorname <- x %>% xml_node("redner") %>% xml_node("vorname") %>% xml_text()
  redner_nachname <- x %>% xml_node("redner") %>% xml_node("nachname") %>% xml_text()
  redner_fraktion <- x %>% xml_node("redner") %>% xml_node("fraktion") %>% xml_text()
  redner_rolle <- x %>% xml_node("rolle_kurz") %>% xml_text()

  data_frame(rede_id, redner_id, redner_vorname, redner_nachname, redner_fraktion, redner_rolle)
}
```

Wir können mit dieser Funktion nun die vorher eingelesen XML-Datei in einen Datenframe umwandeln und auswerten.

```
overview_df <- get_overview_df(prot_overview)
```

```
overview_df
```

```
## # A tibble: 144 x 6
```

```
##   rede_id redner_id redner_vorname redner_nachname redner_fraktion
```

```
##   <chr>    <chr>      <chr>          <chr>          <chr>
```

```
## 1 ID1961~ 11003196 Andrea Nahles SPD
## 2 ID1961~ 11004873 Ulrike Schielke-Ziesi~ AfD
## 3 ID1961~ 11002666 Hermann Gröhe CDU/CSU
## 4 ID1961~ 11004179 Johannes Vogel FDP
## 5 ID1961~ 11004012 Matthias W. Birkwald DIE LINKE
## 6 ID1961~ 11003578 Markus Kurth BÜNDNIS 90/DIE~
## 7 ID1961~ 11003142 Hubertus Heil <NA>
## 8 ID1961~ 11004856 Jürgen Pohl AfD
## 9 ID1961~ 11002812 Max Straubinger CDU/CSU
## 10 ID1961~ 11004941 Gyde Jensen FDP
## # ... with 134 more rows, and 1 more variable: redner_rolle <chr>
```

Wir konnten mit wenigen Zeilen Code das XML-Format in einen Datenframe umwandeln, welcher uns die weitere Arbeit erheblich erleichtert. So könnten wir sehr schnell sagen, wie viele Reden es von den einzelnen Fraktionen zur 61. Sitzung des 19. Bundestags gab:

```
overview_df %>%
  group_by(redner_fraktion) %>%
  summarise(reden = n()) %>%
  arrange(-reden)
```

```
## # A tibble: 8 x 2
##   redner_fraktion    reden
##   <chr>            <int>
## 1 CDU/CSU           41
## 2 SPD               27
## 3 AfD              20
## 4 BÜNDNIS 90/DIE GRÜNEN 16
## 5 FDP              16
## 6 DIE LINKE         15
## 7 <NA>              6
## 8 fraktionslos       3
```


Da *NA* Fraktionen sind dabei die Reden von Ministern und Gästen. Sie werden keiner Fraktion zugeordnet. Insgesamt gab es 144 Reden an diesem Tag.

Uns interessieren natürlich nun nicht nur die Anzahl der Reden, sondern auch deren Inhalt. Wir untersuchen hierfür alle Knoten eine Ebene unter den “rede”-Knoten.

```
prot_speeches <- prot_file %>%
  xml_find_all("//rede/*")
```

Wir bauen wieder eine Funktion, um alle Inhalte der Reden zu extrahieren. Diese Funktion ist ein wenig komplexer, da sie unter anderem die Funktion `map()` aus dem `purrr` Paket nutzt (ebenfalls `tidyverse`) – für weitere Informationen über die Funktion `map()` bietet sich dieses Tutorial an.

Außerdem müssen die Rohdaten etwas angepasst werden, da die Aussagen des Präsidiums sonst falsch zugeordnet werden.

```
get_speeches_df <- function(x){
  raw <- x
  rede <- x %>% xml_text()
  id <- x %>% xml_node("redner") %>% xml_attr("id")
  vorname <- x %>% xml_node("vorname") %>% xml_text()
  nachname <- x %>% xml_node("nachname") %>% xml_text()
  fraktion <- x %>% xml_node("fraktion") %>% xml_text()
  rolle <- x %>% xml_node("rolle_kurz") %>% xml_text()
  typ <- x %>% xml_name()
  status <- x %>% xml_attr("klasse")

  data_frame(raw, rede, id, vorname, nachname, fraktion, rolle, typ, status) %>%
    mutate(rede_id = map(raw, ~xml_parent(.) %>% xml_attr("id")) %>% as.character())
    select(-raw) %>%
    mutate(status = ifelse(typ == "kommentar", typ, status)) %>%
    mutate(status = ifelse(typ == "name", "präsidium", status)) %>%
    mutate(fraktion = case_when(
```

```

    typ == "name"      ~ "präsidium",
    !is.na(rolle)      ~ "andere",
    TRUE              ~ fraktion)) %>%
fill(id, vorname, nachname, fraktion) %>%
mutate(präsidium = ifelse(fraktion == "präsidium", TRUE, FALSE)) %>%
mutate(fraktion = ifelse(fraktion == "präsidium", NA, fraktion)) %>%
filter(!status %in% c("T_NaS", "T_Beratung", "T_fett", "redner")) %>%
filter(!typ %in% c("a", "fussnote", "sup")) %>%
select(rede_id, rede, id, vorname, nachname, fraktion, präsidium, typ, status)
}

get_overview_df <- function(x){
  rede_id <- x %>% xml_attr("id")
  redner_id <- x %>% xml_node("redner") %>% xml_attr("id")
  redner_vorname <- x %>% xml_node("redner") %>% xml_node("vorname") %>% xml_text()
  redner_nachname <- x %>% xml_node("redner") %>% xml_node("nachname") %>% xml_text()
  redner_fraktion <- x %>% xml_node("redner") %>% xml_node("fraktion") %>% xml_text()
  redner_rolle <- x %>% xml_node("rolle_kurz") %>% xml_text()
  sitzung <- x %>% xml_find_first("//sitzungsnr") %>% xml_text() %>% as.integer()
  datum <- x %>% xml_find_first("//datum") %>% xml_attr("date") %>% lubridate::dmy()
  wahlperiode <- x %>% xml_find_first("//wahlperiode") %>% xml_text() %>% as.integer()

  data_frame(rede_id, redner_id, redner_vorname, redner_nachname, redner_fraktion, rede,
             typ, status, sitzung, datum, wahlperiode)
}

speeches_df <- get_speeches_df(prot_speeches)

```

Mittels dieses Datenframes ist es nun möglich, nur die Aussagen von beispielsweise Andrea Nahles zu untersuchen – ohne Unterbrechungen und Fragen von anderen Abgeordneten “mitzuschneiden” oder Aussagen des Präsidiums mitzunehmen.

Hier ein Beispiel:

```
speeches_df %>%  
  filter(typ != "kommentar") %>%  
  filter(präsidium == FALSE) %>%  
  filter(id == "11003196") %>%  
  pull(rede) %>%  
  cat(fill = TRUE)
```

```
## Herr Präsident! Meine lieben Kolleginnen und Kollegen! Auch in dieser Woche verabs  
## Mit der heutigen Rentenreform vollziehen wir einen grundsätzlichen Richtungswechsel  
## Wir sichern damit ein Rentenniveau auf dem heutigen Level. Das ist wirklich eine s  
wenn sie eben ergänzend gedacht ist, nicht ersetzend. Das ist der entscheidende Punkt  
## Denn die gesetzliche Rentenversicherung ist und bleibt die zentrale Säule im deuts  
## Die Rentenreform folgt einem einfachen Prinzip: Wer ein Leben lang arbeitet, der v  
## Ich betone: Ich benutze den Begriff „verdient“ bewusst. Denn die Rente ist kein Al  
## Uns ist die Stärkung der umlagefinanzierten Rente ja auch deswegen so wichtig, weil  
## Im Gegensatz zu den privaten steht die gesetzliche Rente blendend da. Würde man au  
## Die umlagefinanzierte Rente ist deswegen der kapitalgedeckten überlegen.  
## Ich spreche jetzt in diesem Hohen Haus auch etwas aus, was vielleicht nicht alle g  
## oder wir lassen zu, dass die Renten immer weiter sinken und entwertet werden.  
## Wenn wir das aber zulassen, muss die junge Generation einem solchen System irgendw  
## Deswegen ist aus meiner Sicht die Sicherung des Rentenniveaus in diesem System auc  
## Jetzt sagen manche, das sei nicht finanzierbar. Das ist ein ziemlich scheinheiliges  
## Denn niemand wird ja wohl bestreiten, dass das Geld für eine auskömmliche Rente im  
## Das, was wir heute beschließen, ist finanziert. Bis 2025 ist das Rentenniveau klar  
## Wir steigen darüber hinaus in die Bildung einer Demografierücklage ein.  
## Damit schaffen wir die Voraussetzung, um den Steueranteil zur Finanzierung der Ren  
## Das wird wahrscheinlich auch der Weg der Zukunft sein. Darüber wird aber in der Re  
## Wenn es aber etwas gibt, was wir klären müssen, dann ist das doch die Frage: Wollen  
## Einen Weg zur Finanzierung werden wir in einem reichen Land wie Deutschland sicher  
## Letzter Satz. Wenn es also einen Gradmesser für die soziale Sicherheit in Deutschl  
## Vielen Dank.
```

Somit könnten wir für dieses Protokoll die einzelnen Reden (aber zum Beispiel auch Zwischenfragen) von Abgeordneten gezielt auf deren Inhalte untersuchen. Wir können noch nicht die Zwischenrufe und den Applaus nach Abgeordneten bzw. Fraktionen auswerten. Dies wäre mit sogenannten *regular experections* aber möglich.

Wie wir alle aktuellen Protokolle auswerten, behandeln wir in Kapitel 3.

3. Erhebung der Daten des 19. Bundestags

Leider gibt es keine Möglichkeit, die XML-Protokolle des Deutschen Bundestages gesammelt herunterzuladen. Zwar finden sich auf *Open Data*-Seite des Bundestags¹ die Verweise auf die Bundestagsprotokolle, allerdings können diese nur umständlich einzeln heruntergeladen werden. Durch das Auslesen der Netzwerkdaten nach einem Klick auf die nächsten fünf Protokolle eine Webseite gefunden werden, auf welcher jeweils fünf Protokolle gespeichert sind². Durch setzen des `offset=0` auf 5, 10, 15, 20, ... können wir die weiteren Protokolle abrufen.

Mittels `rvest` und `xml2` ziehen wir uns zunächst die Nummer des letzten Bundestagsprotokolls. Über die Funktion `seq()` und `paste0()` können wir anschließend alle für den weiteren Verlauf notwendigen URLs erstellen.

```
bt_website <- "https://www.bundestag.de/ajax/filterlist/de/service/opendata/-/543410"

last_protocol <- bt_website %>%
  read_html() %>%
  xml_find_first("//strong") %>%
  xml_text(trim = TRUE) %>%
  str_extract("\\d+")

prot_websites <- paste0(bt_website, "?offset=", seq(0, last_protocol, 5))
```

Insgesamt müssen wir also 13 Webseiten aufrufen und uns jeweils fünf Protokolle herunterladen.

Der Aufwand ist hier noch überschaubar. Natürlich laden wir die Protokolle dennoch nicht per Hand herunter, sondern erstellen uns hierfür ein kleines Script. Da die meisten

¹<https://www.bundestag.de/service/opendata>

²<https://www.bundestag.de/ajax/filterlist/de/service/opendata/-/543410?offset=0>

Rechner auch mit mehr als nur einem Prozessor ausgestattet sind, können wir die Funktion auch auf mehreren Prozessoren ausführen. Wir sprechen hier von *multiprocessing*. Dies realisieren wir über das Paket `furrr` (Vaughan/Dancho 2018) - eine Abwandlung des bereits genutzten `purrr`.

Wir schreiben uns zunächst eine Funktion, um die Links der Webseiten zu extrahieren.

```
get_prot_links <- function(x){
  x %>%
    read_html() %>%
    html_nodes(".bt-link-dokument") %>%
    html_attr("href") %>%
    paste0("https://www.bundestag.de", .)
}

get_prot_links(bt_website)
```

```
## [1] "https://www.bundestag.de/blob/578466/7430bccaf792e7bc55e84d5e64675820/19062-d
## [2] "https://www.bundestag.de/blob/577958/e2063c0f51a32690a269f48aa6102c1d/19061-d
## [3] "https://www.bundestag.de/blob/577622/da97888b713abb16ed2070836504b83a/19060-d
## [4] "https://www.bundestag.de/blob/575138/b5395a975d1c55838da0e52251018160/19059-d
## [5] "https://www.bundestag.de/blob/574826/0e3659e11c1c3cdbfa621369cd16735a/19058-d
```

Dies wenden wir nun auf alle 13 Webseiten an und speichern die Dateien anschließend im Ordner `data\protokolle`.

```
library(furrr)
plan(multiprocess)

prot_links <- future_map(prot_websites, ~get_prot_links(.)) %>% unlist()

prot_links %>% future_map(~download.file(., file.path("data/protokolle", basename(.))
```

Wir waren erfolgreich und konnten in wenigsten Sekunden alle aktuellen Protokolle herun-

terladen. Wir können sie jetzt auslesen und dabei auch unsere bereits erstellten Funktionen verwenden.

```
prot_files <- list.files("data/protokolle", full.names = TRUE)

prot_extract <- map(prot_files, ~read_html(.) %>% xml_find_all("//rede"))

class(prot_extract) <- "xml_nodeset"

prot_overview <- map_dfr(prot_extract, ~get_overview_df(.))
```

3.1. Überblick der Reden

Wir konnten nun alle Dateien herunterladen und anschließend alle Protokolle in R einlesen. Mit unserer Funktion `get_overview_df()` konnten wir alle Protokolle in einen für uns passenden Datenframe umwandeln. Insgesamt können wir derzeit 5.777 Reden des aktuellen Bundestags untersuchen – etwa nach der Person, welche die meisten reden gehalten hat.

```
prot_overview %>%
  group_by(redner_id, redner_vorname, redner_nachname,
           redner_fraktion, redner_rolle) %>%
  summarise(reden = n()) %>%
  arrange(-reden)
```

```
## # A tibble: 773 x 6
## # Groups:   redner_id, redner_vorname, redner_nachname, redner_fraktion
## #   [728]
##   redner_id redner_vorname redner_nachname redner_fraktion redner_rolle
##   <chr>      <chr>          <chr>          <chr>          <chr>
## 1 11002617 Peter          Altmaier      <NA>          Bundesminis~
## 2 999990073 Olaf           Scholz        <NA>          Bundesminis~
```

Tabelle 3.1.: Reden Nach Fraktion im Deutschen Bundestag

redner_fraktion	reden
CDU/CSU	1353
SPD	962
AfD	784
FDP	683
BÜNDNIS 90/DIE GRÜNEN	662
NA	662
DIE LINKE	606
fraktionslos	63
Bremen	1
Bündnis 90/Die Grünen	1

```
## 3 11004427 Volker      Ullrich      CDU/CSU      <NA>
## 4 11001478 Angela      Merkel      <NA>         Bundeskanzler~
## 5 11004809 Heiko        Maas        <NA>         Bundesminister~
## 6 11004851 Frauke        Petry        fraktionslos <NA>
## 7 11004798 Alexander Graf Lambsdorff FDP          <NA>
## 8 11003625 Andreas        Scheuer      <NA>         Bundesminister~
## 9 999990074 Svenja      Schulze      <NA>         Bundesminister~
## 10 11003638 Jens          Spahn        <NA>         Bundesminister~
## # ... with 763 more rows, and 1 more variable: reden <int>
```

Die Minister_innen haben am häufigsten im Bundestag geredet, der MdB Volker Ullrich landet erst auf Platz 4 mit insgesamt vierzig Reden in der aktuellen Wahlperiode. Überraschenderweise hat Frauke Petry sehr viele Reden gehalten: 35 Stück. Das sind deutlich mehr als in ihrer damaligen Zeit im Landesparlament.

Wir können die Reden auch nach Fraktionen auswerten:

```
prot_overview %>%
  group_by(redner_fraktion) %>%
  summarise(reden = n()) %>%
  arrange(-reden) %>%
  knitr::kable(caption = "Reden Nach Fraktion im Deutschen Bundestag", booktabs = TRUE)
```


Mit Auswertung der Daten nach Fraktion stellen wir kleinere Probleme fest: Anscheinend wurden die Grünen in einem Dokument nicht in der üblichen Schreibweise geschrieben. Und die Fraktion “Bremen” ist vermutlich auch in der falschen Spalte gelandet - es handelt sich nämlich um eine Rede des Bremer Bürgermeisters. Beide ändern wir entsprechend:

```
prot_overview <- prot_overview %>%
  mutate(redner_fraktion = ifelse(redner_fraktion == "Bündnis 90/Die Grünen", "BÜNDNIS 90/DIE GRÜNEN", redner_fraktion))
  mutate(redner_fraktion = ifelse(redner_fraktion == "Bremen", NA, redner_fraktion))
```

3.2. Inhalte der Reden

Auch die Inhalte der Reden sollen aus allen Protokollen ausgelesen werden. Eine Auswertung erfolgt später.

```
speech_extract <- map(prot_files, ~read_html(.) %>% xml_find_all("//rede/*"))

class(speech_extract) <- "xml_nodeset"

prot_speeches <- map_dfr(speech_extract, ~get_speeches_df(.))
```

3.3. Daten der Abgeordneten

Wir haben nun die Reden als auch die Inhalte der Reden im Bundestag heruntergeladen. Dabei haben wir auch schon Verweise auf die Fraktionen und auch die Rollen (beispielsweise die Rede als Bundesminister_in) generieren können. Es fehlen uns jedoch noch Aussagen über das Geschlecht der Redner_innen (und weitere Daten – etwa Alter, Ausschussmitgliedschaften und Amtszeit).

Diese können wir abermals über das Open Data Portal³ des Bundestags herunterladen. Es handelt sich um eine ZIP-Datei, welche wir zunächst herunterladen und anschließend

³<https://www.bundestag.de/service/opendata>

extrahieren.

```
link_zip <- "https://www.bundestag.de/blob/472878/e207ab4b38c93187c6580fc186a95f38/mo

download.file(link_zip, file.path("data/", basename(link_zip)))

unzip("data/mdb-stammdaten-data.zip", exdir = "data/")

file_stammdaten <- read_xml("data/MDB_STAMMDATEN.XML")
```

Nachdem die Datei heruntergeladen und ausgelesen wurde, können wir die Daten wieder einen *Dataframe* umwandeln.

```
get_data_mdb <- function(x){
  id <- x %>% xml_find_all("//ID") %>% xml_text()
  geschlecht <- x %>% xml_find_all("//ID/following-sibling::BIOGRAFISCHE_ANGABEN/GESCHLECHT") %>% xml_text()
  geburtsjahr <- x %>% xml_find_all("//ID/following-sibling::BIOGRAFISCHE_ANGABEN/GEBOURTSDATUM") %>% xml_text()
  partei <- x %>% xml_find_all("//ID/following-sibling::BIOGRAFISCHE_ANGABEN/PARTEI") %>% xml_text()
  wahlperioden <- x %>% xml_find_all("//ID/following-sibling::WAHLPERIODEN") %>% xml_text()

  data_frame(id, geschlecht, geburtsjahr, partei, wahlperioden) %>%
    mutate(wahlperioden = map(wahlperioden, ~xml_nodes(., "WP") %>% xml_text() %>% as.integer())) %>%
    mutate(anzahl_wahlperioden = map(wahlperioden, ~length(.)) %>% unlist())
}

data_mdb <- get_data_mdb(file_stammdaten)

data_mdb
```

```
## # A tibble: 4,073 x 6
```

```
##   id      geschlecht geburtsjahr partei wahlperioden anzahl_wahlperioden
##   <chr>    <chr>          <int> <chr>  <list>          <int>
## 1 11000001 männlich      1930 CDU    <int [7]>          7
## 2 11000002 männlich      1909 FDP    <int [5]>          5
```

Tabelle 3.2.: Bundestagsabgeordnete aller Wahlperioden nach Geschlecht

geschlecht	n	freq
männlich	3223	0.7913086
weiblich	850	0.2086914

```
## 3 11000003 weiblich      1913 CDU    <int [3]>      3
## 4 11000004 weiblich      1933 CDU    <int [2]>      2
## 5 11000005 männlich      1950 CDU    <int [5]>      5
## 6 11000007 männlich      1919 SPD    <int [4]>      4
## 7 11000008 männlich      1912 CDU    <int [1]>      1
## 8 11000009 männlich      1876 CDU    <int [5]>      5
## 9 11000010 weiblich      1944 SPD    <int [4]>      4
## 10 11000011 männlich     1920 CDU    <int [3]>      3
## # ... with 4,063 more rows
```

Die Namen brauchen wir nicht zwingend, da wir dies auch den bestehenden Daten entnehmen können (außerdem haben wir ein kleine Problem mit Abgeordneten, welche während oder zwischen den Wahlperioden den Nachnamen ändern oder ergänzen). Wichtig ist hier die ID – mit dieser können wir die einzelnen Reden den Abgeordneten und schließlich auch dem jeweiligen Geschlecht zuordnen.

Bei den Stammdaten handelt es sich um die Daten aller Bundestagsabgeordneten seit dem 1. Bundestag, welcher 14. August 1949 gewählt wurde. Insgesamt waren 4.073 Personen im Bundestag vertreten. Wie viele davon weiblich und männlich waren, lässt sich wenigen Zeilen Code darstellen. Die letzten beiden Zeilen des Codes beziehen sich nur auf eine bessere Darstellung in der PDF und der Webseite.

```
data_mdb %>%
  group_by(geschlecht) %>%
  summarise(n = n()) %>%
  mutate(freq = n / sum(n)) %>%
  arrange(-n) %>%
  knitr::kable(caption = "Bundestagsabgeordnete aller Wahlperioden nach Geschlecht",
```

Die große Mehrheit der im Bundestag vertretenen Person ist männlich. Nur eine Minderheit von 20,9% der Abgeordneten war oder ist weiblich. Ein nicht-binäres Geschlecht oder eine Verweigerung der Angabe des Geschlechts wurde bisher noch nicht angegeben oder nicht dokumentiert – trans- und intersexuelle Menschen sind im Bundestag somit auch weiterhin kaum vertreten.⁴

Wir können mit diesen Daten auch mit wenig aufwand die Frauenquote in den jeweiligen Wahlperioden darstellen.

```
data_mdb %>%
  unnest() %>%
  group_by(geschlecht, wahlperioden) %>%
  summarise(n = n()) %>%
  group_by(wahlperioden) %>%
  mutate(freq = n / sum(n)) %>%
  rename(Geschlecht = geschlecht) %>%
  ggplot(aes(x = wahlperioden, y = freq, colour = Geschlecht)) +
  geom_line() +
  labs(title = "Geschlechteranteile im Deutschen Bundestag",
       subtitle = "Auswertung des 1. bis 19. Deutschen Bundestages",
       x = "Wahlperiode",
       y = "Anteil in Prozent") +
  theme_minimal()
```

Wie in Abb. 3.1 zu erkennen, ist mit der aktuellen Wahlperiode der Anteil an Frauen im Bundestag deutlich zurückgegangen. Die Anteil an Frauen im aktuellen Bundestag beträgt aktuell 30,7 %.

⁴Eine Ausnahme ist etwa der Politiker Christian Schenk, welcher sich nach seiner Zeit im Bundestag als Transmann outete und eine Geschlechtsumwandlung vollzog.




Abbildung 3.1.: Auswertung der Geschlechteranteile aller Deutscher Bundestage

4. Auswertung

Nachdem alle Daten abgerufen wurden, können wir uns endlich an die Auswertung machen. Zunächst, wie hoch ist der Frauenanteil nach den einzelnen Fraktionen?

```
data_mdb %>%
  unnest() %>%
  filter(wahlperioden == 19) %>%
  group_by(geschlecht, partei) %>%
  summarise(n = n()) %>%
  group_by(partei) %>%
  mutate(freq = n/sum(n)) %>%
  filter(geschlecht == "weiblich") %>%
  arrange(-freq) %>%
  mutate(freq = scales::percent(freq)) %>%
  select(-geschlecht)
```

```
## # A tibble: 8 x 3
## # Groups:   partei [8]
##   partei          n freq
##   <chr>        <int> <chr>
## 1 BÜNDNIS 90/DIE GRÜNEN    39 58.2%
## 2 DIE LINKE.              37 53.6%
## 3 Blaue                   1 50.0%
## 4 SPD                    65 41.9%
## 5 FDP                    19 23.7%
## 6 CDU                    41 20.5%
## 7 CSU                     8 17.4%
## 8 AfD                    10 10.9%
```

Wie hoch ist der Anteil an Reden von Frauen im Bundestag?

```
data_mdb %>%
  unnest() %>%
  filter(wahlperioden == 19) %>%
  select(-geburtsjahr, -anzahl_wahlperioden, -wahlperioden) %>%
  left_join(prot_overview, by = c("id" = "redner_id")) %>%
  group_by(geschlecht) %>%
  summarise(n = n()) %>%
  mutate(freq = n/sum(n)) %>%
  mutate(freq = scales::percent(freq))
```

```
## # A tibble: 2 x 3
##   geschlecht      n freq
##   <chr>      <int> <chr>
## 1 männlich    3894 68.8%
## 2 weiblich   1765 31.2%
```

Überraschenderweise höher als der Anteil an weiblichen Abgeordneten. Wie sieht es für die einzelnen Parteien an. Untersuchen wir den Anteil an Reden von Frauen.

```
data_mdb %>%
  unnest() %>%
  filter(wahlperioden == 19) %>%
  select(-geburtsjahr, -anzahl_wahlperioden, -wahlperioden) %>%
  left_join(prot_overview, by = c("id" = "redner_id")) %>%
  group_by(geschlecht, redner_fraktion) %>%
  summarise(n = n()) %>%
  group_by(redner_fraktion) %>%
  mutate(freq = n/sum(n)) %>%
  filter(geschlecht == "weiblich") %>%
  arrange(-freq) %>%
  mutate(freq = scales::percent(freq))
```

```
## # A tibble: 8 x 4
```

```
## # Groups:   redner_fraktion [8]
##   geschlecht redner_fraktion      n freq
##   <chr>      <chr>            <int> <chr>
## 1 weiblich   BÜNDNIS 90/DIE GRÜNEN  407 61.4%
## 2 weiblich   fraktionslos           35 55.6%
## 3 weiblich   DIE LINKE              304 50.2%
## 4 weiblich   SPD                    367 38.5%
## 5 weiblich   <NA>                   202 36.4%
## 6 weiblich   FDP                    167 24.5%
## 7 weiblich   CDU/CSU                202 14.9%
## 8 weiblich   AfD                     81 10.3%
```

Der Anteil an Reden von Frauen ist sowohl bei der SPD, der CDU/CSU, den Linken und auch der AfD niedriger als der Anteil an weiblichen Abgeordneten. Besonders deutlich fällt dies aber bei der Fraktion CDU/CSU aus. Bei der Fraktion der Grünen ist der Anteil an Reden von Frauen hingegen sogar noch höher als der Anteil an weiblichen Abgeordneten.

Die keiner Fraktion zugeordneten Reden stammen vor allem von Regierungsmitgliedern. Nur bei Regierungsmitgliedern mit einem Mandat für den Bundestag kann ein Geschlecht zugeordnet werden – der Anteil an Reden weiblicher Regierungsmitglieder fällt somit wohnmöglich höher aus.

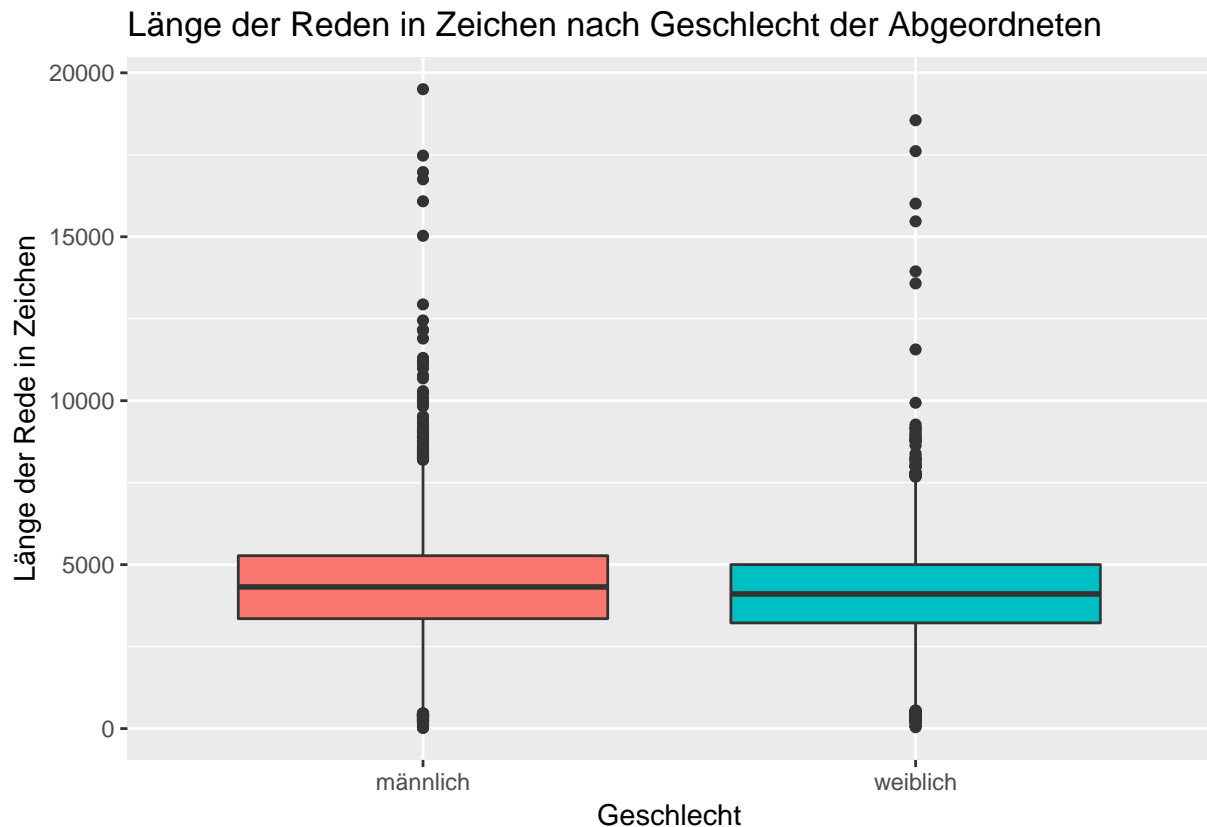
Der überraschend hohe Anteil an Reden weiblicher Abgeordneter bei den Fraktionslosen abgeordneten geht auf Frauke Petry zurück, welche besonders häufig am Podium des Bundestags zu sehen ist – siehe 3.1.

4.1. Länge der Reden

Wir können nun auch die Reden der Politiker_innen analysieren. Etwa, indem wir die durchschnittliche Länge (in Zeichen) zwischen Männern und Frauen vergleichen.


```
avg_rede_leange <- data_mdb %>%
  unnest() %>%
  select(-geburtsjahr, -anzahl_wahlperioden) %>%
  filter(wahlperioden == 19) %>%
  left_join(prot_overview, by = c("id" = "redner_id")) %>%
  left_join(prot_speeches, by = c("rede_id")) %>%
  filter(präsidium == FALSE) %>%
  filter(typ != "kommentar") %>%
  filter(!is.na(redner_fraktion)) %>%
  filter(id.x == id.y) %>%
  mutate(rede_laenge = nchar(rede)) %>%
  group_by(geschlecht, rede_id) %>%
  rename(Geschlecht = geschlecht) %>%
  summarise(rede_laenge = sum(rede_laenge))

ggplot(avg_rede_leange, aes(x = Geschlecht, y = rede_laenge, fill = Geschlecht)) +
  geom_boxplot() +
  labs(title = "Länge der Reden in Zeichen nach Geschlecht der Abgeordneten",
       x = "Geschlecht", y = "Länge der Rede in Zeichen") +
  guides(fill = FALSE)
```




Wir sehen, dass Frauen durchschnittlich eine etwas geringere Redezeit aufweisen als Männer. Die tatsächliche Redezeit konnte allerdings nicht bestimmt werden, wir nähern uns durch die Anzahl der Zeichen in der Rede an einen solchen Wert an. Die Abweichung zwischen den Redezeiten erscheint jedoch marginal. Hier könnte noch zwischen den Fraktionen unterschieden werden. Wir vergleichen die Redezeiten von Frauen nach Fraktion:

```
data_mdb %>%
  unnest() %>%
  select(-geburtsjahr, -anzahl_wahlperioden) %>%
  filter(wahlperioden == 19) %>%
  left_join(prot_overview, by = c("id" = "redner_id")) %>%
  left_join(prot_speeches, by = c("rede_id")) %>%
  filter(präsidium == FALSE) %>%
  filter(typ != "kommentar") %>%
  filter(!is.na(redner_fraktion)) %>%
  filter(redner_fraktion != "fraktionslos") %>%
  filter(id.x == id.y) %>%
```

```

mutate(rede_laenge = nchar(rede)) %>%
group_by(geschlecht, rede_id, redner_fraktion) %>%
rename(Geschlecht = geschlecht, Fraktion = redner_fraktion) %>%
summarise(rede_laenge = sum(rede_laenge)) %>%
ggplot(aes(x = Fraktion, y = rede_laenge, fill = Fraktion)) +
geom_boxplot() +
facet_wrap(~Geschlecht) +
labs(title = "Länge der Rede in Zeichen nach Fraktion und Geschlecht",
      y = "Länge der Rede in Zeichen", x = "") +
coord_flip() +
guides(fill = FALSE)

```



Hier sind kaum Unterschiede zwischen den verschiedenen Fraktionen festzustellen. (DIE FARBEN WERDEN NOCH AN DIE FRAKTIONEN ANGEPAßT). Als nächstes stehen die Inhalte der Reden an.

4.2. Inhalte der Reden


Wenn wir nach besonders häufigen Wörtern suchen würden, würden wir nur auf Stopwörter stoßen (der, die, das, ich, bin, ...). Das wäre wenig gewinnbringend. Wir suchen deshalb nach Wörtern, welche häufiger vorkommen, aber nicht zu häufig – und sich zwischen den Gruppen besonders unterscheiden. Wir greifen hierbei auf die *Term Frequency and Inverse Document Frequency* (tf-idf) Berechnung (Ramos 2003). HIER KOMMT NOCH DIE ERKLÄRUNG VON TF-IDF UND WIESO ES BEI ZWEI GRUPPEN (BZW. DOKUMENTEN) EHER NICHT GEEIGNET IST.

```
library(tidytext)

speech_gender_words <- data_mdb %>%
  unnest() %>%
  select(-geburtsjahr, -anzahl_wahlperioden) %>%
  filter(wahlperioden == 19) %>%
  left_join(prot_overview, by = c("id" = "redner_id")) %>%
  left_join(prot_speeches, by = c("rede_id")) %>%
  filter(präsidium == FALSE) %>%
  filter(typ != "kommentar") %>%
  filter(!is.na(redner_fraktion)) %>%
  filter(redner_fraktion != "fraktionslos") %>%
  filter(id.x == id.y) %>%
  group_by(geschlecht) %>%
  summarise(rede = paste(rede, collapse = " ")) %>%
  ungroup() %>%
  unnest_tokens(word, rede) %>%
  count(geschlecht, word, sort = TRUE)

speech_total_words <- speech_gender_words %>%
  group_by(geschlecht) %>% summarize(total = sum(n))
```

```
speech_gender_words %>%  
  left_join(speech_total_words, by = "geschlecht") %>%  
  bind_tf_idf(word, geschlecht, n) %>%  
  arrange(-tf_idf) %>%  
  mutate(word = factor(word, levels = rev(unique(word)))) %>%  
  group_by(geschlecht) %>%  
  top_n(15) %>%  
  ungroup() %>%  
  ggplot(aes(word, tf_idf, fill = geschlecht)) +  
  geom_col(show.legend = FALSE) +  
  labs(x = NULL, y = "tf-idf") +  
  facet_wrap(~geschlecht, ncol = 2, scales = "free") +  
  coord_flip()
```



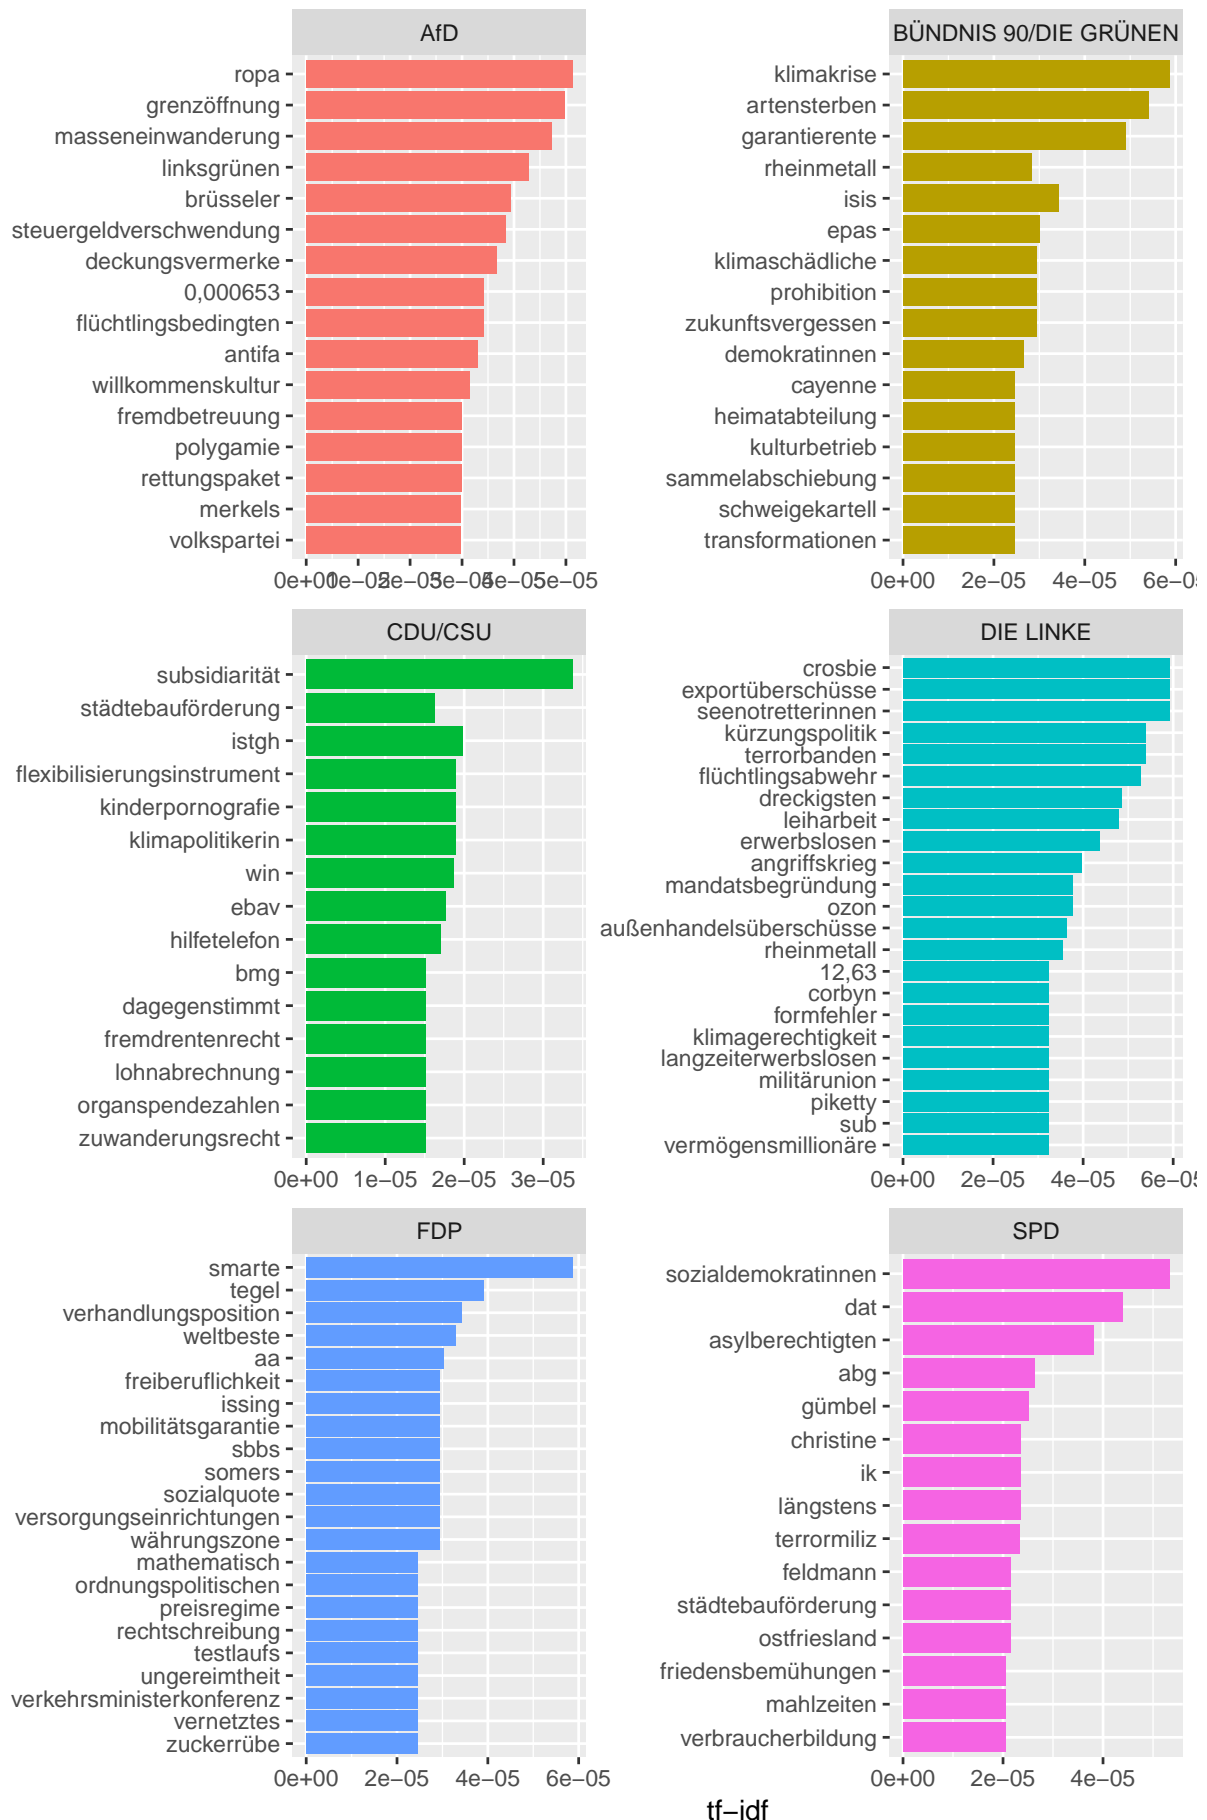
Wir können tf-idf natürlich auch auf die Fraktionen anwenden:

```
speech_fraktion_words <- data_mdb %>%
  unnest() %>%
  select(-geburtsjahr, -anzahl_wahlperioden) %>%
  filter(wahlperioden == 19) %>%
  left_join(prot_overview, by = c("id" = "redner_id")) %>%
  left_join(prot_speeches, by = c("rede_id")) %>%
  filter(präsidium == FALSE) %>%
  filter(typ != "kommentar") %>%
  filter(!is.na(redner_fraktion)) %>%
  filter(redner_fraktion != "fraktionslos") %>%
```

```
filter(id.x == id.y) %>%
group_by(redner_fraktion) %>%
summarise(rede = paste(rede, collapse = " ")) %>%
ungroup() %>%
unnest_tokens(word, rede) %>%
count(redner_fraktion, word, sort = TRUE)

fraktion_total_words <- speech_fraktion_words %>%
  group_by(redner_fraktion) %>% summarize(total = sum(n))

speech_fraktion_words %>%
  left_join(fraktion_total_words, by = "redner_fraktion") %>%
  bind_tf_idf(word, redner_fraktion, n) %>%
  arrange(-tf_idf) %>%
  mutate(word = factor(word, levels = rev(unique(word)))) %>%
  group_by(redner_fraktion) %>%
  top_n(15) %>%
  ungroup() %>%
  ggplot(aes(word, tf_idf, fill = redner_fraktion)) +
  geom_col(show.legend = FALSE) +
  labs(x = NULL, y = "tf-idf") +
  facet_wrap(~redner_fraktion, ncol = 2, scales = "free") +
  coord_flip()
```



WIRD NOCH VERVOLLSTÄNDIGT

5. Topic Modeling

Mit LDA und dem preisgekrönten stm (Roberts et al. 2018). Wird noch vervollständigt.

Literatur- und Quellverzeichnis

Bäck, Hanna/Debus, Marc/Müller, Jochen (2014): Who Takes the Parliamentary Floor? The Role of Gender in Speech-Making in the Swedish "Riksdag". In: *Political Research Quarterly*, 67 (3), 504–518.

Ramos, Juan Enrique (2003): Using TF-IDF to Determine Word Relevance in Document Queries. Präsentiert auf: 2003,

R Core Team (2018): R: A Language and Environment for Statistical Computing. Vienna, Austria: R Foundation for Statistical Computing. Text abrufbar unter: <https://www.R-project.org/>.

Roberts, Margaret E./Stewart, Brandon M./Tingley, Dustin (2018): Stm: R Package for Structural Topic Models. Text abrufbar unter: <http://www.structuraltopicmodel.com>.

Vaughan, Davis/Dancho, Matt (2018): Furr: Apply Mapping Functions in Parallel Using Futures. Text abrufbar unter: <https://CRAN.R-project.org/package=furr>.

Wangnerud, Lena (2000): Testing the Politics of Presence: Women's Representation in the Swedish Riksdag. In: *Scandinavian Political Studies*, 23 (1), 67–91.

Wickham, Hadley (2016): Rvest: Easily Harvest (Scrape) Web Pages. Text abrufbar unter: <https://CRAN.R-project.org/package=rvest>.

Wickham, Hadley (2017): Tidyverse: Easily Install and Load the 'Tidyverse'. Text abrufbar unter: <https://CRAN.R-project.org/package=tidyverse>.

Wickham, Hadley/Hester, James/Ooms, Jeroen (2018): Xml2: Parse XML. Text abrufbar unter: <https://CRAN.R-project.org/package=xml2>.